

AP1 - Análise Exploratória de dados.

O exercício de a seguir deverá ser entregue no dia da avaliação. Esta parte da avaliação valerá 85% da nota de AP1.

Utilize para este exercício o arquivo

AIDS_Classification.csv fornecido.

Desafio 1: A Fundação dos Dados (Data Cleaning)

Cenário: Você recebeu o dataset bruto e notou que algumas colunas categóricas (como gênero e raça) podem estar codificadas de forma que dificultam a leitura imediata para um relatório. Além disso, é necessário garantir que não existam valores nulos que possam distorcer as médias.

Tarefa de Codificação:

1. Verifique se existem valores ausentes no dataset e aplique uma estratégia de limpeza.
2. Certifique-se de que as variáveis age, wtkg (peso) e as contagens de CD4 (cd40, cd420) sejam do tipo numérico (float ou int).
3. Crie uma nova coluna chamada cd4_delta, que representa a variação absoluta na contagem de células CD4 entre o início do estudo e a semana 20
4. **O Storytelling:** Escreva um parágrafo explicando por que a limpeza de dados é o "alicerce" de uma análise clínica confiável. Como um erro de tipo de dado (string

em vez de número) poderia levar a conclusões médicas erradas?

Desafio 2: O Escudo Imunológico (Box Plots)

Cenário: A diretoria do hospital quer entender a distribuição do peso (wtkg) e da idade (age) entre os pacientes que tiveram sucesso no tratamento vs. aqueles que progrediram para a infecção (infected).

Tarefa de Codificação:

1. Utilize a biblioteca **Seaborn** ou **Matplotlib** para gerar dois **Box Plots** lado a lado.
 2. O primeiro gráfico deve mostrar a distribuição de wtkg para os dois grupos de infected.
 3. O segundo deve mostrar a distribuição de age para os mesmos grupos.
 4. Identifique visualmente se existem *outliers* (valores discrepantes) em algum dos grupos.
 5. **O Storytelling:** Analise as medianas e a dispersão (os "bigodes" do gráfico). Existe alguma evidência visual de que pacientes mais jovens ou mais leves correm mais risco? O que os *outliers* nos dizem sobre casos excepcionais na medicina?
-

Desafio 3: A Eficácia dos Protocolos (Gráficos de Barras)

Cenário: Existem quatro tratamentos diferentes no dataset (coluna trt). Precisamos descobrir qual deles apresenta o melhor desempenho médio na manutenção das células de defesa.

Tarefa de Codificação:

1. Agrupe os dados pelo tipo de tratamento (trt).
2. Calcule a média da contagem de CD4 na semana 20 (cd420) para cada tratamento.
3. Gere um **Gráfico de Barras** comparando essas médias.
4. Adicione uma cor diferente para destacar o tratamento que obteve o melhor resultado (a maior média).
5. **O Storytelling:** Imagine que você está apresentando este gráfico para um comitê de ética médica. Use os dados para defender o investimento em um dos protocolos de tratamento específicos. Como você explicaria a diferença de performance entre o melhor e o pior tratamento apenas olhando para as barras?

Desafio 4: Correlações Ocultas (Scatter Plot e Estatística)

Cenário: Há uma teoria de que a contagem inicial de CD4 (cd40) é o principal preditor do estado do paciente após 20 semanas.

Tarefa de Codificação:

1. Crie um **Gráfico de Dispersão (Scatter Plot)** relacionando cd40 (eixo X) e cd420 (eixo Y).

2. Utilize o parâmetro `hue` para colorir os pontos de acordo com a variável `symptom` (presença de sintomas).

3. **Desafio : O Storytelling:** O gráfico mostra uma linha reta ascendente ou os pontos estão muito espalhados? Interprete o valor da correlação: se o paciente começa com um sistema imunológico fraco, o tratamento consegue reverter isso, ou a tendência é continuar caindo? Use a visualização para narrar a "jornada de recuperação" do paciente médio.

Dica para os alunos:

Ao realizar esses exercícios, foquem não apenas no `plt.show()`, mas em responder à pergunta: **"O que este dado está tentando me dizer que eu não conseguiria ver apenas olhando para a planilha?"**

Exercício: O Risco dos Sintomas Visíveis

Cenário:

Como cientista de dados de uma unidade de saúde, você precisa calcular o risco de progressão da doença. A diretoria quer saber: "Se um paciente já apresenta sintomas no início do estudo, qual a probabilidade dele ser classificado como 'infectado' ao final, em comparação com quem não tem sintomas?"

Enunciado para os Alunos

Tarefa de Codificação:

1. Carregue o arquivo AIDS_Classification.csv.
2. Calcule a **Probabilidade Frequentista** simples: $P(\text{Infected})$.
3. Calcule a **Probabilidade Condicional** de estar infectado dado que o paciente tem sintomas:

$P(\text{Infected} \mid \text{Symptom} = 1)$.

Dica: Para isso, filtre o DataFrame apenas pelos pacientes com sintomas e calcule a média da coluna infected.

4. Calcule a **Probabilidade Condicional** de estar infectado dado que o paciente **não** tem sintomas: $P(\text{Infected} \mid \text{Symptom} = 0)$.
5. Crie um **Gráfico de Barras** comparando essas duas probabilidades condicionais para visualizar o "salto" de risco.

O Storytelling:

Com base nos números calculados, os sintomas iniciais são um "alerta vermelho" confiável? Se um paciente chega à clínica sem sintomas, ele pode ser considerado "fora de perigo", ou a probabilidade de infecção ainda é relevante? Use os dados para justificar se o hospital deve priorizar testes caros apenas em pacientes sintomáticos.

Como resolver isso no Python (Lógica)

Para guiar seu raciocínio, você usará a contagem de casos favoráveis sobre o total de casos possíveis:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$